

Indice Introducción Extracción Transformación Carga

Tema 4. Procesos ETL

Indice

3

- □ Introducción
- Extracción
- □ Transformación
- Carga

-INGP. 2021

3

Tema 4. Procesos ETL

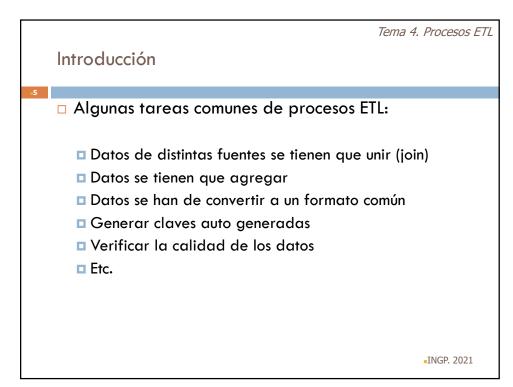
Introducción

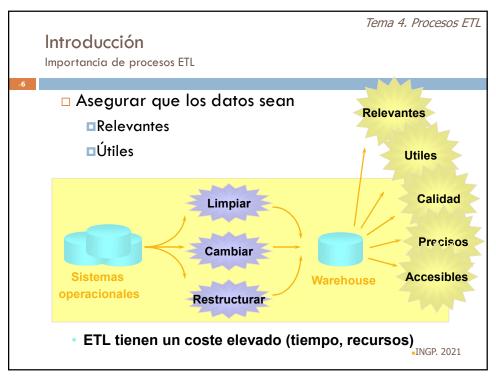
4

- □ Bill Inmon (90's): "Un almacén de datos es una colección de datos orientados por temas, integrados, no volátiles y variables en el tiempo en apoyo de la toma de decisiones estratégicas".
 - Datos procedentes de una gran variedad de fuentes
- □ ETL (Extraction-Transformation-Loading):
 - Extracción de datos desde fuentes de datos operacionales y heterogéneas,
 - Transformación limpieza (conversión, limpieza, normalización, etc.), y
 - □ Carga refresco en el Almacén de datos

INGP. 2021

Л





Tema 4. Procesos ETL

Introducción

Algunas consideraciones generales

-7

- Definir una estrategia de calidad de datos para la empresa según política de toma de decisiones
- □ Definir el nivel de calidad óptimo de los datos
- Considerar el modificar reglas de las fuentes de datos operacionales
- □ Básico → documentar las fuentes
- Diseñar los procesos de limpieza (y sus tareas) de forma muy cuidadosa
- Los procesos de limpieza iniciales puedes variar de los procesos de refresco posteriores

•INGP. 2021

7

Tema 4. Procesos ETL

Introducción

Algunas consideraciones generales

-8

- □ Cuidado → datos incorrectos o engañosos producirán decisiones estratégicas erróneas
- □ El mercado de herramientas de ETL en 2001: sobre \$667 millones in USA
- Esfuerzo en ETL: aprox. 50% del presupuesto total de los proyectos de DW
- Actualmente el diseño y mantenimiento de procesos ETL es todavía un asunto "pendiente"
- Aunque varias herramientas en mercado, no disponemos de modelo o metodología estándar para su diseño desde primeros pasos de un proyecto de DW

-INGP. 2021



J

Introducción Seis pasos detallados: 1. Seleccionar las fuentes para extraer datos 2. Transformar las fuentes 3. Unir las fuentes 4. Seleccionar las estructuras destino a cargar datos (hechos, dimensiones, etc.) 5. Mapear los atributos de las fuentes en los destinos 6. Cargar los datos

Tema 4. Procesos ETL

Introducción

11

- El paso de transformación también puede incluir limpieza de datos (detectar y borrar errores e inconsistencias)
- La creación manual y mantenimiento de los procesos
 ETL aumenta el coste de los DW
- CUIDADO: Documentación con gran cantidad de páginas con código de programas ETL

•INGP. 2021

11

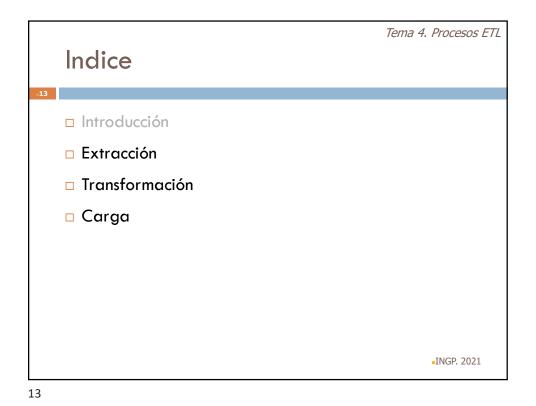
Introducción

Tema 4. Procesos ETL

12

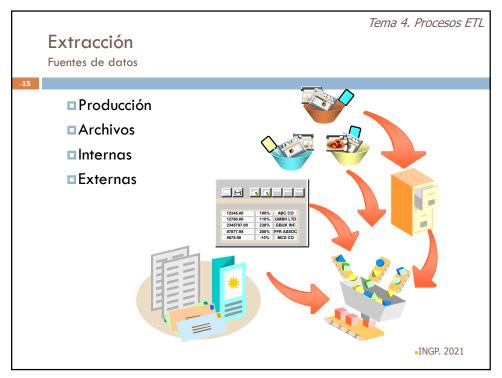
- Tres pasos básicos:
 - 1. Extraer de las fuentes de datos
 - 2. Transformar las fuentes
 - 3. Cargar los datos

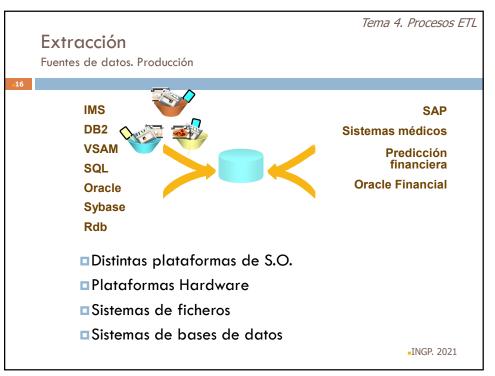
INGP. 2021

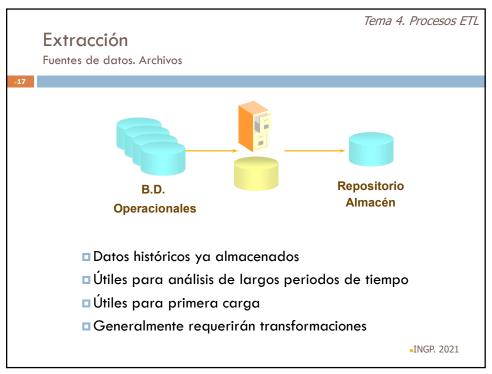


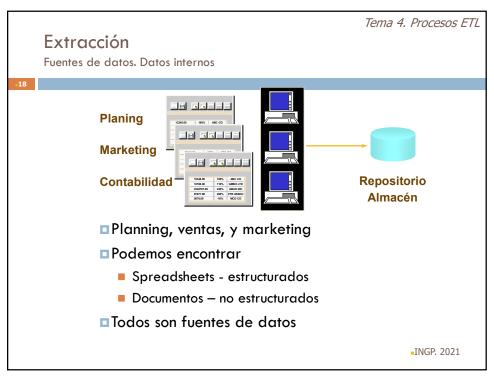
Indice

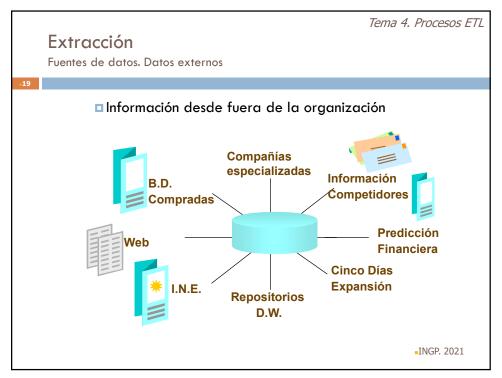
Introducción
Extracción
Transformación
Carga

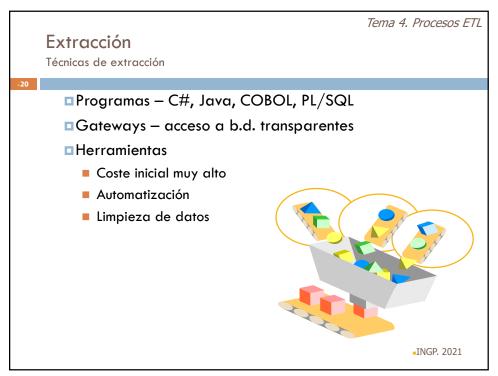


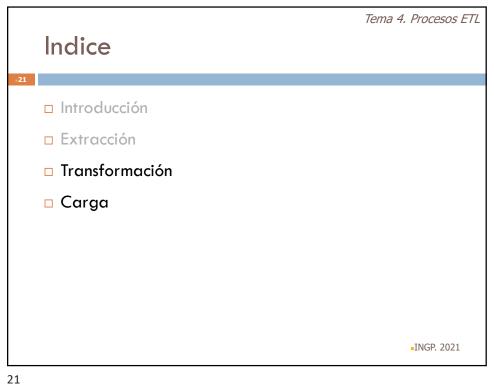




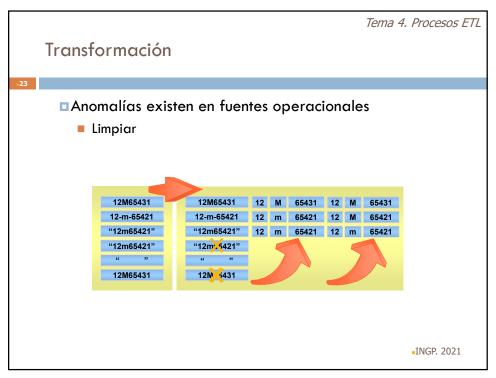




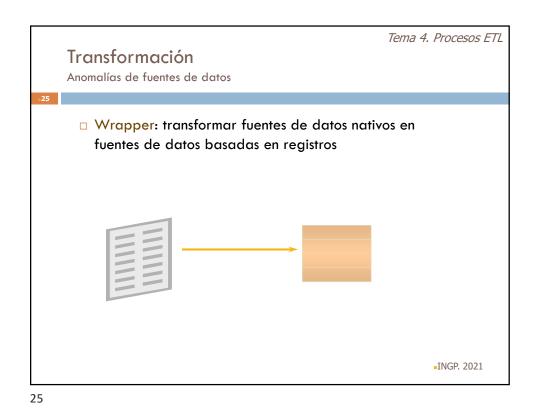


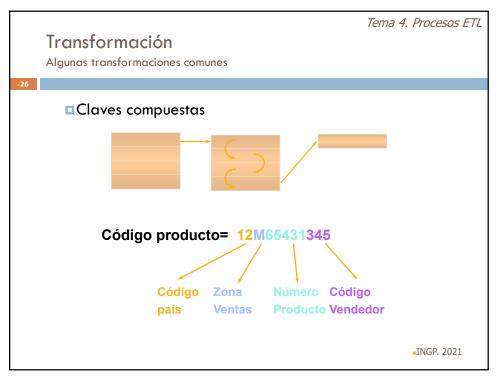


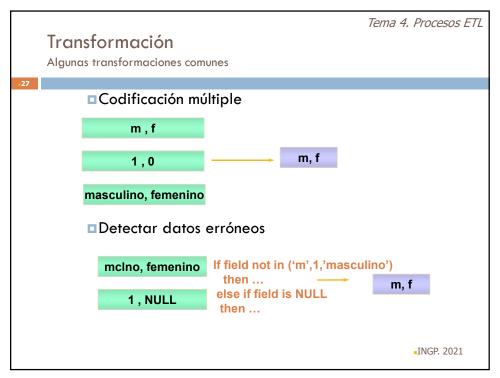
Tema 4. Procesos ETL Indice □ Introducción □ Extracción □ Transformación Carga •INGP. 2021

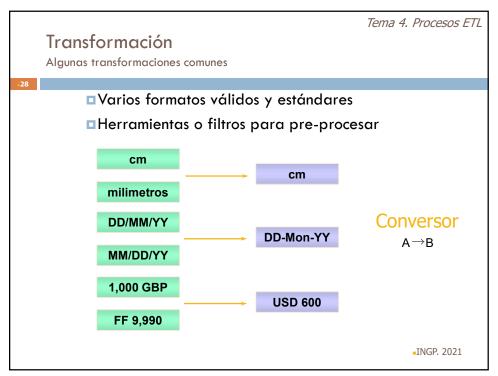


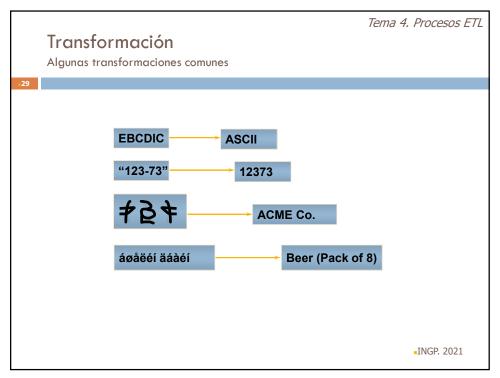


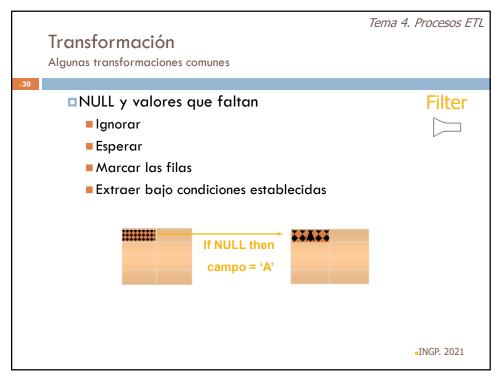


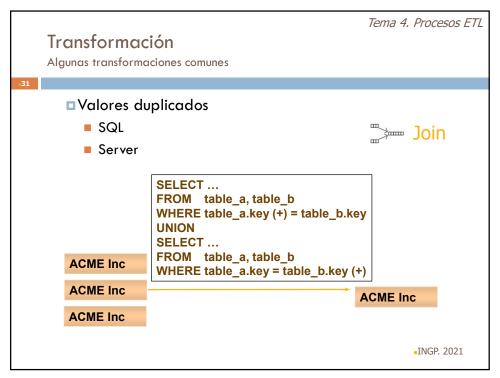


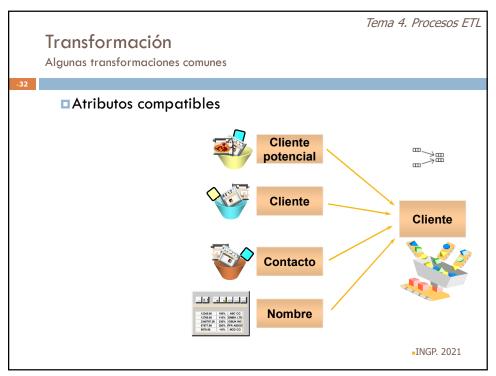


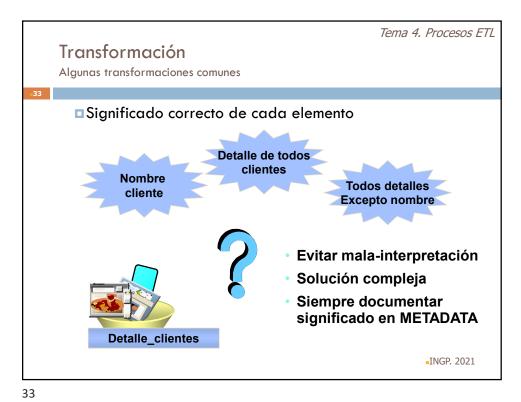


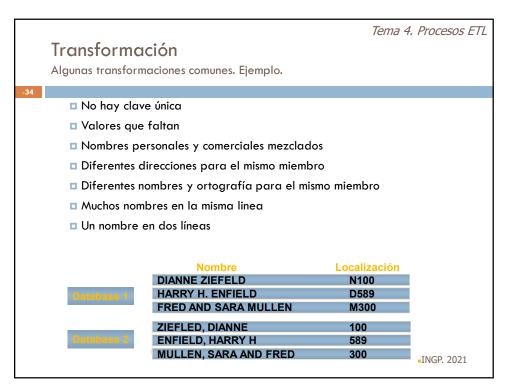


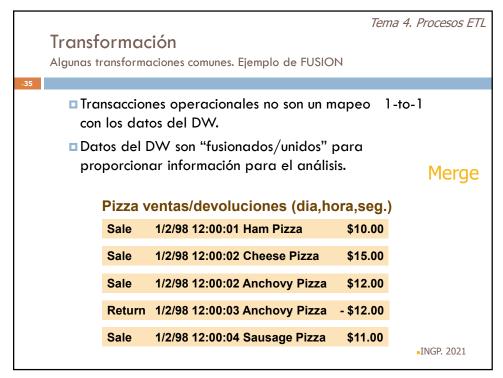








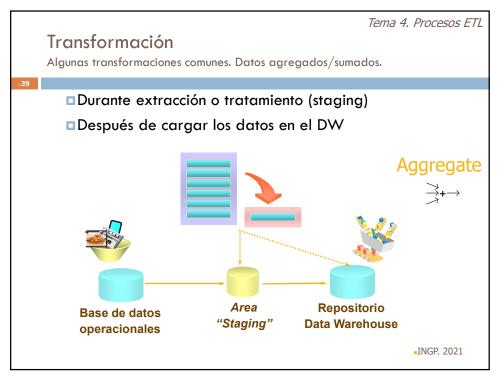


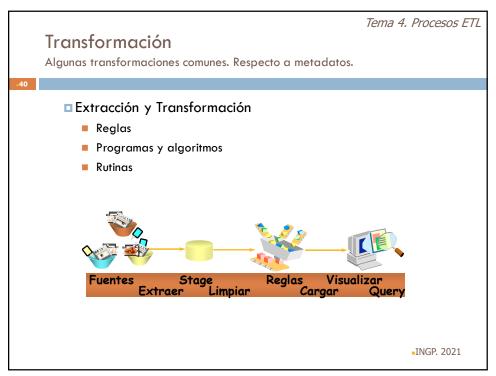


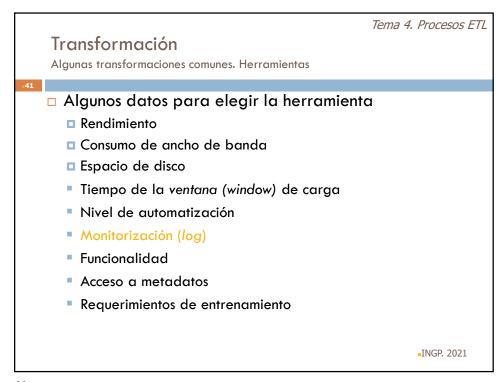


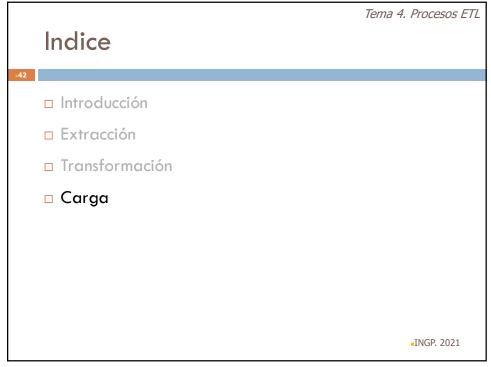












Indice

Introducción
Extracción
Transformación
Carga

Tema 4. Procesos ETL

Carga

Objetivos

44

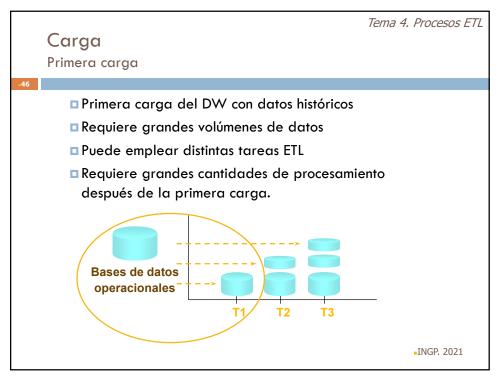
43

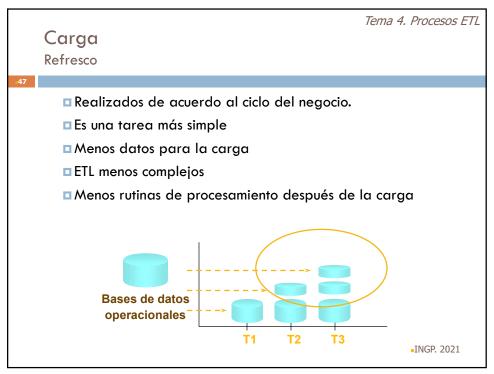
- Identificar el transporte de datos para la primera vez y refrescos siguientes.
- Describir consideraciones estratégicas e implementar el refresco de datos
- Identificar métodos empleados para capturar cambios en los datos y, aplicarlos en el DW
- □ Describir técnicas de transporte.
- □ Identificar las tareas que se llevan a cabo después de que los datos se cargan.

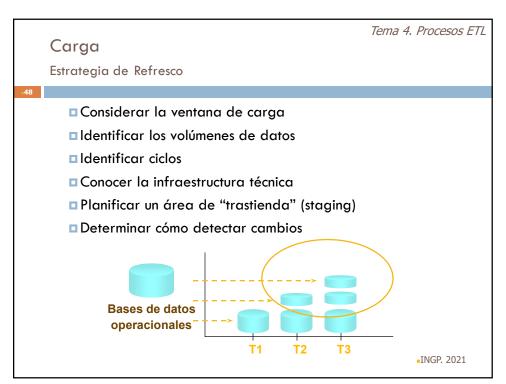
-INGP. 2021

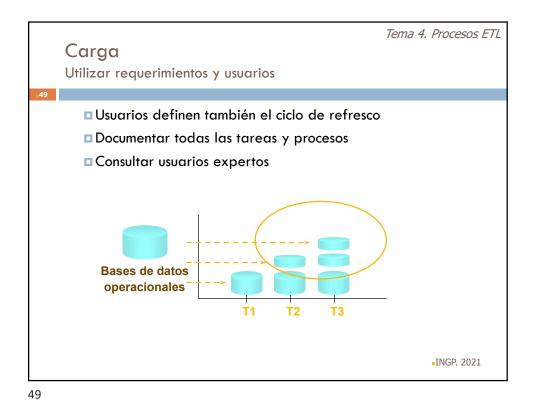
Carga
Planteamiento general

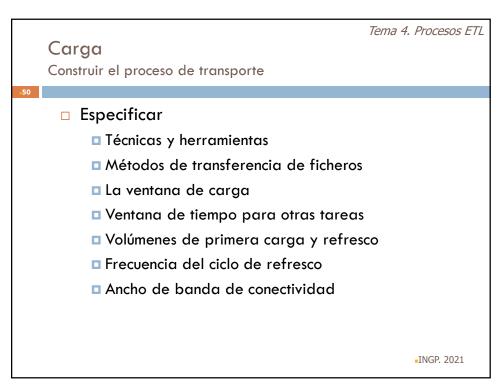
Carga (loading) lleva los datos al DW.
Carga puede necesitar mucho tiempo:
Considerar la ventana de carga
Planificar → intentar automatizar todos los procesos
Carga inicial mueve grandes volumen.
Cargas posteriores mueven volumen de datos más pequeños.
El "negocio" determinar el ciclo de las cargas.

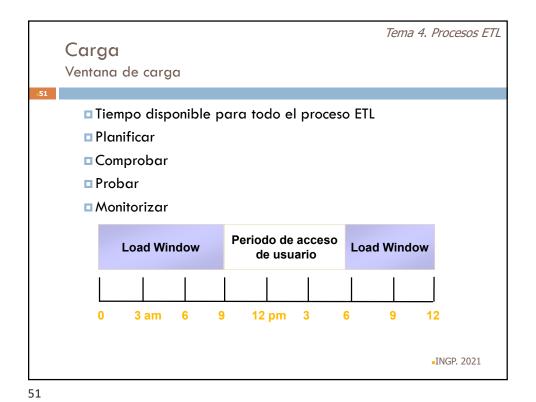




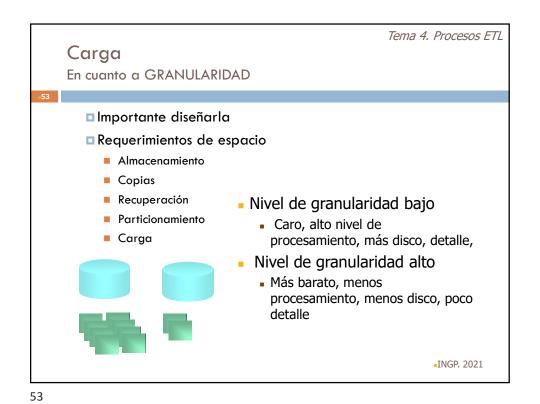




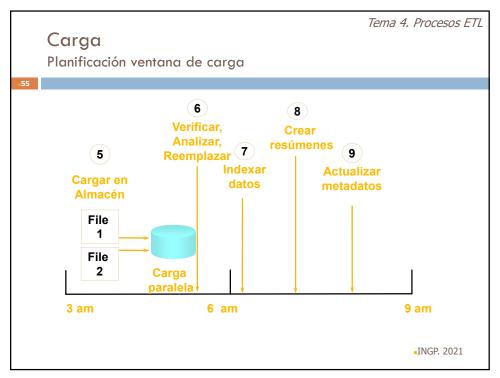


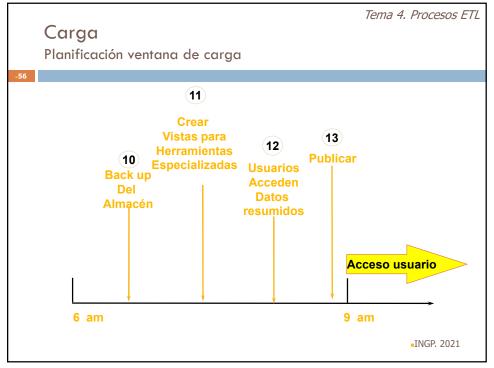


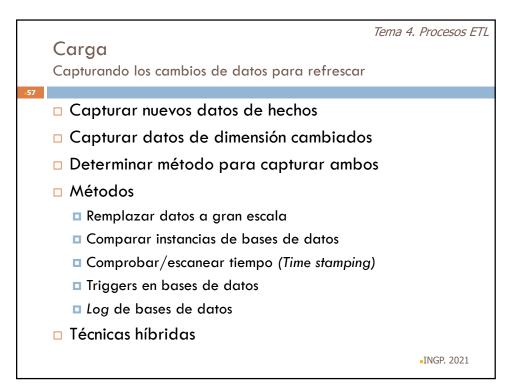
Tema 4. Procesos ETL Carga Ventana de carga □ Planificar y construir procesos de acuerdo a una estrategia. ■ Considerar volúmenes de datos □ Identificar infraestructura técnica ■ Asegurar la actualidad de los datos □ Considerar en primer lugar los requerimientos de acceso de usuarios ■ Muchos requerimientos puede significar una ventana de carga pequeña Periodo de acceso de usuario •INGP 2021 3 am 12 pm

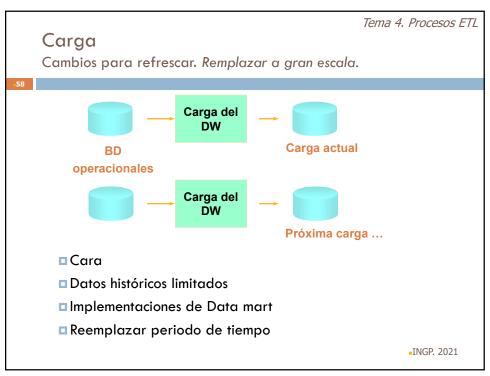


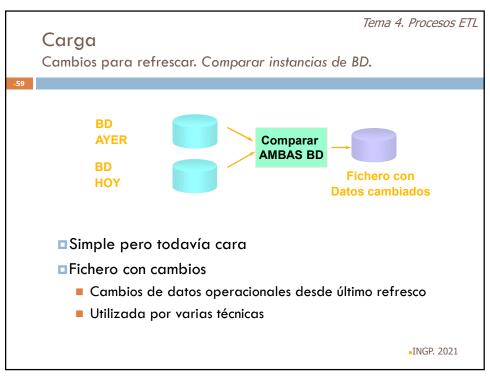
Tema 4. Procesos ETL Carga Planificación ventana de carga (1) Requerimientos Ciclo de carga (3) **Datos Abrir** Fichero de control recibidos Nombre de fichero leer File Tipos de fichero ficheros 1 Número de filas para Número de cargas verificar File Primera vez de la carga 2 Fecha de fichero analizar Fecha de los refrescos Registros del fichero-count Total - amounts Proceso De control 0 3 am -INGP. 2021

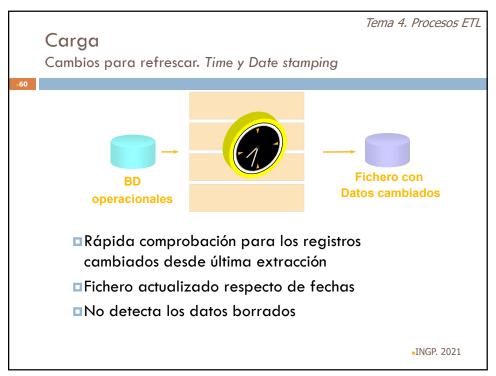


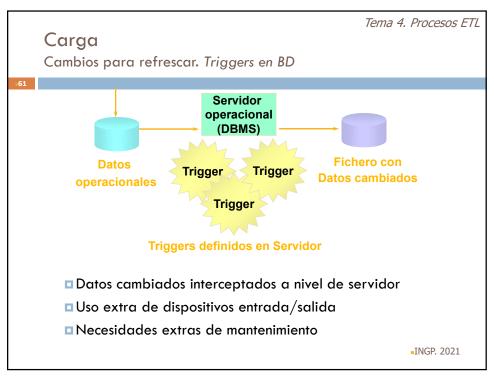


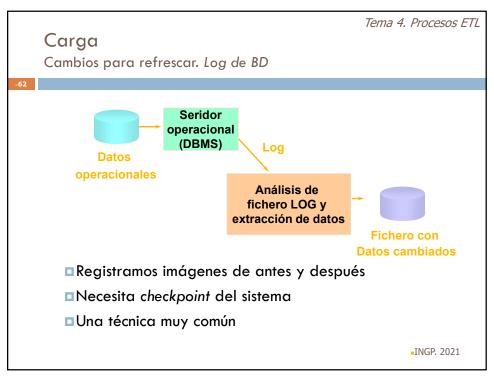












Tema 4. Procesos ETL

Carga

Cambios para refrescar. Entonces QUE ???

63

- Analizar cada método de forma individual
- Considerar una solución híbrida si un solo método no es adecuado
- Considerar elementos como aplicaciones actuales,
 BD operacionales disponibles y tecnología actual disponible.

•INGP. 2021

Tema 4. Procesos ETL

63

Carga

Cambios para refrescar. COMO APLICAR CAMBIOS ?

64

□ Para adoptar soluciones de políticas según cambios en operacionales ver soluciones de Kimball para dimensiones y hechos que cambian lenta y rápidamente (Tema 4)

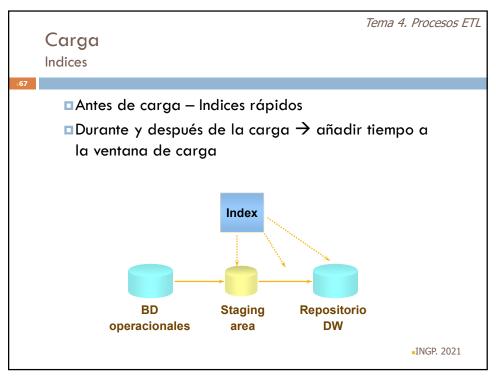
INGP. 2021

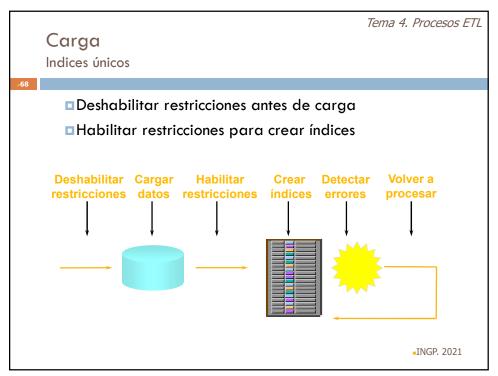
Carga
Técnicas de transporte

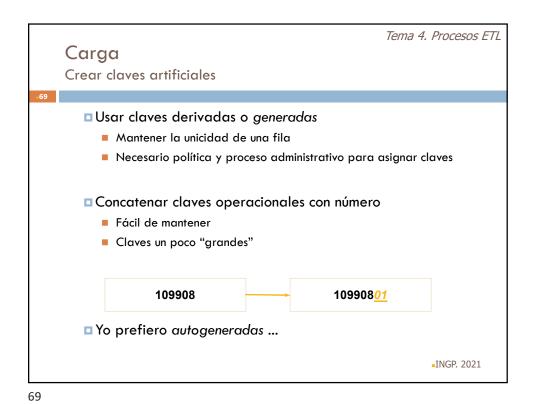
Herramientas
Utilidades y lenguajes de programación
Gateways
Programas de copias personalizados
Réplicas
FTP
Totalmente manual

65

Carga Cambios para refrescar. COMO APLICAR CAMBIOS ? Herramientas son adecuadas pero CARAS Utilidades son rápidas y potentes Gateways no siempre son los + rápidos Acceso a otras BD Soportar entorno distribuido Proporcionar acceso en tiempo real si necesario Siempre se suele necesitar tratamiento posterior de la carga (Post-processing)



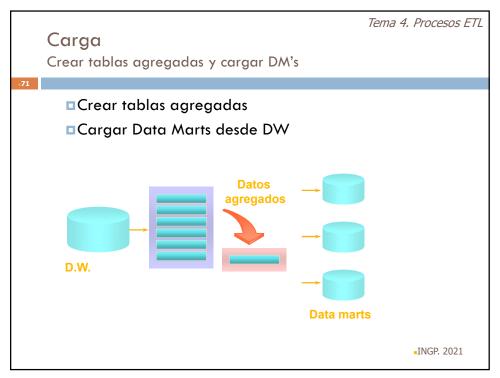


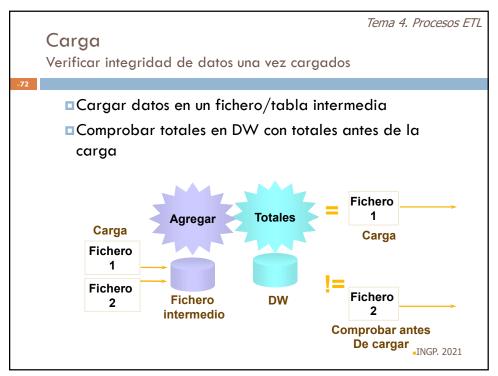


Carga
Crear claves únicas/autogeneradas

Asignar un número de una lista
Sin significado semántico
Operaciones de extracción deben referenciar a las tablas operacionales para asignar números

109908
1
Actualizar metadata
Comprobar finalmente





Carga
Comprobar datos cargados

Estatus de la carga (log)
Proceso finalizado
Todos datos cargados
Comprobar violaciones
Lanzar procesos de nuevo ???
Comprobar los datos agregados

Tareas finales después de carga

Actualizar metadata

ETL

Usuarios

Publicar nuevos datos

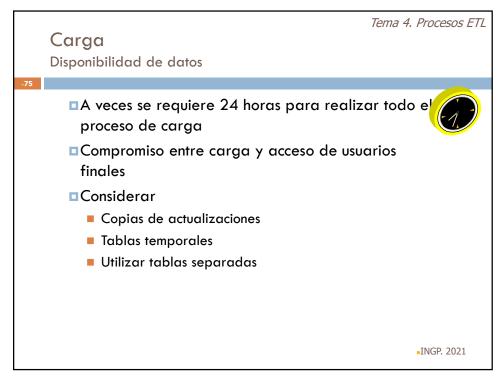
Disponibilidad

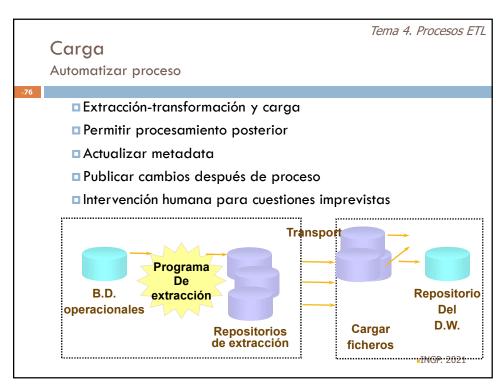
Cambios

Vistas de negocio

Aspectos de seguridad para accesos no deseados

74





Tema 4. Procesos ETL

Carga

Diseño de procesos de extracción

Análisis

Fuentes, tecnologías

Tipos de datos fuentes, calidad, propietarios

Opciones de diseño

Manual, personalizados, gateway, terceros

Replicar total o parcialmente

□ Elementos de diseño

Volúmenes de datos, actualizados, copias

Automatizar, tecnología disponible

■INGP. 2021

Tema 4. Procesos ETL

77

Carga

Diseño de procesos de transformación

-78

Análisis

- Mapeos de fuentes y destino (DW), reglas de negocio
- Granularidad, claves, metadatos,...
- Opciones de diseño
 - PL/SQL, replicar, clientes, terceros
- □Elementos de diseño
 - Rendimiento
 - Tamaño del pre-procesamiento
 - Manejo de excepción, mantenimiento de integridad

INGP. 2021

